

Pipeline de ML, Otimização e Decisão de Manutenção — Complexo Petroquímico

Dataset: petrochemical_advanced_data.csv — 10.000 registros, 16 colunas, janeiro de 2020 a julho de 2024 Integrantes:

- Elton Vinícios Almeida de Oliveira — RM 562187
- Emerson dos Santos Silva — RM 562033
- Kelvin Douglas Ribeiro Rabelo — RM 561538
- Pedro Henrique Simão Soares — RM 562283
- Vitor Lucas Mattos de Brito Mariano — RM 562116

1. Entendimento do negócio

O trabalho busca uma configuração operacional que reduza a intensidade energética sem produzir menos que o nível de referência e, em seguida, compara alternativas de manutenção. Há quatro decisões operacionais: vazão, temperatura, pressão e abertura de válvula. A condição do equipamento é representada por saúde do sensor, vibração e idade/tipo do catalisador.

Variável	Classe	Uso
Feedstock_Flow_m3h	Controlável	Variável de decisão
Reactor_Temp_C	Controlável	Variável de decisão
Reactor_Pressure_Bar	Controlável	Variável de decisão
Valve_Opening_Percent	Controlável	Variável de decisão
Sensor_Health_Index	Estado	Indicador de condição; não prova falha
Vibration_Level_mm_s	Estado	Indicador de condição mecânica
Catalyst_Age_Days / Catalyst_Type	Estado	Condição do catalisador
Unit_Name	Estado categórico	Unidade produtiva
Ambient_Temp_C / Timestamp	Externa	Ambiente e sazonalidade
Electricity_MWh / Natural_Gas_m3h / Steam_Tons_h	Resultado pós-operação	Excluídas dos modelos operacionais
Product_Yield_Tons	Target	Produção por intervalo de quatro horas
Energy_Intensity	Target	Intensidade energética por tonelada

Regras adotadas: validação temporal; targets e medições pós-operação fora das features; limites calculados na própria unidade; restrição de produção; restrição de proximidade a configurações observadas; custos e risco tratados como premissas didáticas.

Resumo do tratamento das 16 colunas originais:

Papel	Quantidade	Tratamento
Entradas disponíveis antes da operação	11	Usadas como features ou para criar features
Targets	2	Product_Yield_Tons e Energy_Intensity

Papel	Quantidade	Tratamento
Medições pós-operação	3	Electricity_MWh, Natural_Gas_m3h e Steam_Tons_h; excluídas das features
Features derivadas	5	Hora e mês em seno/cosseno e interação Flow × Health

Para prever energia, o Product_Yield_Tons observado também é excluído, pois só é conhecido depois da operação; o pipeline usa a produção prevista. “Excluída das features” não significa removida da análise: eletricidade e gás são usados para auditar a identidade do target e, somente no conjunto de treino, calcular a referência energética do modelo híbrido. Vapor não participa da fórmula e não entra no modelo.

2. Dados e Machine Learning

2.1 Qualidade e exploração

A base não possui nulos, duplicatas completas nem timestamps duplicados. As leituras estão espaçadas em quatro horas e distribuídas de forma equilibrada entre três unidades. As médias dos targets também são semelhantes entre unidades. Vazão e saúde apresentam as associações mais fortes com produção e energia. Temperatura, pressão e válvula têm importância preditiva pequena dentro do domínio observado.

Foram criadas features cíclicas de hora e mês. Unit_Name e Catalyst_Type receberam one-hot encoding. A auditoria também identificou a interação pré-operacional Feedstock_Flow_m3h × Sensor_Health_Index.

Exploração por produto/unidade

Como não existe uma coluna específica de produto, Unit_Name foi usado como proxy para comparar amônia, etileno e metanol.

Produto/unidade	Registros	Energy Intensity média	Product Yield médio (ton/4h)
Amônia	3.347	2,886	80,26
Etileno	3.354	2,882	80,38
Metanol	3.299	2,887	80,01

As diferenças são muito pequenas. A unidade explica apenas 0,001% da variância de intensidade energética e 0,012% da produção. Como teste adicional, comparamos um Gradient Boosting global com modelos separados por unidade, sempre nos mesmos 20% finais da série temporal:

Target	Produto/unidade	RMSE global	RMSE separado
Energia	Amônia	0,337	0,343
Energia	Etileno	0,352	0,358
Energia	Metanol	0,338	0,340
Produção	Amônia	0,136	0,150
Produção	Etileno	0,149	0,149
Produção	Metanol	0,209	0,242

Não houve ganho consistente com a separação; para energia, o modelo global foi melhor nas três unidades. Assim, mantivemos um único modelo e a avaliação por unidade apenas como diagnóstico de monitoramento. A segmentação não foi aprofundada porque reduziria cada treino para aproximadamente um terço da base sem benefício observado.

Essa conclusão vale para este dataset sintético; produtos reais com processos, preços, margens ou limites próprios devem ser reavaliados separadamente.

2.2 Target leakage

Target leakage ocorre quando o modelo recebe uma informação que contém a resposta, mas que ainda não estaria disponível no momento real da decisão. A regra adotada foi simples: se a variável só é conhecida depois da operação, ela não entra como feature pré-operacional. Caso contrário, o erro de teste poderia parecer excelente sem representar uma previsão utilizável.

As constantes foram obtidas dos próprios dados, não assumidas. Usamos os primeiros 70% da série para descobri-las e todos os 10.000 registros para validar as relações. Primeiro definimos $\text{Energy_Intensity} \times \text{Product_Yield_Tons}$ como a energia equivalente observada e ajustamos, por mínimos quadrados sem intercepto, seus coeficientes em relação a Electricity_MWh e Natural_Gas_m3h . O ajuste devolveu 3,600 para eletricidade e 0,035 para gás, com erro máximo de reconstrução de aproximadamente $1,99 \times 10^{-13}$ nas 10.000 linhas antes da divisão pela produção.

Na fórmula da base, 3,6 coloca a eletricidade na escala de GJ e coincide com a conversão de 1 MWh para 3,6 GJ. O fator 0,035 representa 0,035 GJ, ou 35 MJ, por m^3 de gás. Eles são usados para somar as duas fontes em uma medida de energia equivalente. Como a base não documenta formalmente o balanço físico e a coluna de gás está expressa como vazão, esses fatores devem ser tratados como parte da regra sintética do dataset, não como parâmetros universais ou oficiais da planta.

Assim, a auditoria encontrou a identidade exata, com erro numérico máximo de $3,55 \times 10^{-15}$ após a divisão:

$$\text{Energy_Intensity} = (3,6 \times \text{Electricity_MWh} + 0,035 \times \text{Natural_Gas_m3h}) / \text{Product_Yield_Tons}$$

Portanto, os valores observados de eletricidade, gás e produção da mesma operação não podem ser entradas para prever sua intensidade energética. Steam_Tons_h não participa dessa fórmula, mas também é uma medição posterior e foi excluída.

Para descobrir a constante de produção, calculamos no treino a razão $\text{Product_Yield_Tons} / (\text{Feedstock_Flow_m3h} \times \text{Sensor_Health_Index})$ e validamos nas 10.000 linhas. A média, mediana, mínimo e máximo são 0,18, com desvio-padrão de aproximadamente $2,01 \times 10^{-17}$. O 0,18 é o fator de produção embutido no gerador sintético; ele converte vazão ajustada pela saúde em toneladas por intervalo neste dataset, mas não deve ser generalizado para uma planta real. Foi encontrada a identidade exata, com erro máximo de $4,26 \times 10^{-14}$:

$$\text{Product_Yield_Tons} = 0,18 \times \text{Feedstock_Flow_m3h} \times \text{Sensor_Health_Index}$$

Como vazão e saúde estão disponíveis antes da operação, a interação não é leakage. Ela revela, porém, que a produção da base é sintética e determinística. No modelo de energia, também não usamos eletricidade, gás ou produção reais da linha prevista: usamos apenas uma referência energética média aprendida no treino e a produção estimada com variáveis disponíveis antes da operação.

2.3 Validação e resultados

Os primeiros 80% formam a janela de desenvolvimento e os 20% finais permanecem intocados até a avaliação final. Dentro do desenvolvimento, 70% ajustam o modelo operacional e 10% calibram a incerteza. Três folds walk-forward expansivos (5.000→1.000, 6.000→1.000 e 7.000→1.000) verificam estabilidade sem usar o teste final.

Target	Modelo	R ²	MAE	RMSE
Energy_Intensity	Linear Regression	0,6801	0,2810	0,3472
Energy_Intensity	Random Forest	0,6825	0,2794	0,3459
Energy_Intensity	Gradient Boosting	0,6888	0,2766	0,3424
Energy_Intensity	Híbrido físico	0,6930	0,2761	0,3401

Target	Modelo	R ²	MAE	RMSE
Product_Yield_Tons	Linear + interação	1,0000	0,0000	0,0000
Product_Yield_Tons	Random Forest	0,9999	0,0126	0,1250
Product_Yield_Tons	Gradient Boosting	0,9999	0,1092	0,1678
Product_Yield_Tons	Híbrido físico	1,0000	0,0000	0,0000

No walk-forward de energia, Gradient Boosting e híbrido ficam tecnicamente empatados: RMSE médio $0,3311 \pm 0,0050$ e $0,3312 \pm 0,0049$, respectivamente. No teste final, o híbrido alcança RMSE 0,3401, contra 0,3424 do Gradient Boosting. Ele foi escolhido pela coerência algébrica e interpretabilidade, não por ajuste ao teste.

A janela separada de 1.000 registros calibrou uma margem conformal absoluta de 90% igual a 0,552. No teste final, o intervalo cobriu 89,4% das observações, valor próximo dos 90% nominais. Para produção, a margem é apenas erro numérico ($1,42 \times 10^{-14}$).

A interação de vazão e saúde domina a previsão de produção. Essa relação determinística descreve como a base foi construída, mas não demonstra que uma manutenção real causará toda a recuperação simulada.

3. Otimização

3.1 Formulação

Seja $x = (\text{Valve_Opening}, \text{Feedstock_Flow}, \text{Reactor_Temp}, \text{Reactor_Pressure})$. Para cada estado do equipamento:

$$\min \text{El_hat}(x \mid \text{estado}) + 10^{-4} D(x, x_{\text{atual}})$$

sujeito a:

$$\text{Yield_hat}(x \mid \text{estado}) \geq 64,37 \text{ ton/4h}$$

x entre p1 e p99 do histórico da unidade

distância conjunta até uma configuração observada $\leq$ p99 histórico

O termo de movimento apenas desempata soluções em favor de ajustes menores. Usamos `scipy.optimize.differential_evolution` porque a razão de energia e a restrição de vizinhança tornam o problema não linear. Uma busca aleatória com 10.000 candidatos e uma LP com surrogates lineares funcionam como verificações independentes. A distância de suporte combina setpoints, saúde, vibração e idade do catalisador dentro do mesmo ativo/unidade.

3.2 Caso de estudo e estado pós-manutenção

O caso não foi escolhido manualmente. Ele é o maior escore de degradação no período de teste, combinando baixa saúde (50%), alta vibração (35%) e idade do catalisador (15%): Ammonia_Unit_02 em 12/05/2024, saúde 0,578, vibração 8,126 mm/s e catalisador com 348 dias.

O estado pós-manutenção também deixou de combinar percentis extremos artificiais. Ele é uma observação real e central de um grupo saudável da mesma unidade e catalisador no treino: saúde 0,970, vibração 1,749 mm/s e 58 dias.

3.3 Solução

Variável	Sem manutenção	Manutenção imediata
Valve Opening (%)	79,91	79,53
Feedstock Flow (m³/h)	694,11	694,11
Reactor Temperature (°C)	789,03	795,14

Variável	Sem manutenção	Manutenção imediata
Reactor Pressure (bar)	33,36	33,32
Energy Intensity prevista	3,106	1,849
Product Yield previsto (ton/4h)	72,20	121,25
Distância de suporte condicionado	2,032	1,035
Limite de suporte	2,032	2,032

As duas soluções satisfazem a produção mínima e permanecem na região conjunta condicionada ao estado. A solução sem manutenção fica próxima do limite de suporte; a solução pós-manutenção permanece mais central. Como o numerador energético não é previsível com as entradas disponíveis, minimizar intensidade equivale principalmente a elevar a produção. Temperatura, pressão e válvula não devem ser interpretadas como alavancas comprovadas de economia.

3.3 Alternativas por faixa de produção

A fronteira estrita energia–produção colapsa em um ponto, pois o numerador energético é aproximadamente constante e a intensidade cai quando a produção aumenta. Para evitar operar sempre no extremo, foram calculadas metas de produção pós-manutenção com faixa de tolerância de 2%:

Meta relativa à produção atual	Flow	Yield	EI	Distância de suporte
140%	526,21	91,92	2,439	0,799
150%	563,79	98,48	2,276	0,903
160%	601,38	105,05	2,134	0,929
165%	620,17	108,33	2,069	0,968

Essas alternativas permitem escolher capacidade e intensidade conforme a margem operacional, em vez de aceitar automaticamente a configuração de maior produção.

3.4 Otimização robusta

A formulação robusta minimiza o limite superior conformal de intensidade e exige o limite inferior de produção acima da meta. Com manutenção, a intensidade passa de 1,849 nominal para limite superior 2,401; sem manutenção, de 3,105 para 3,657. Os setpoints não mudam porque a margem energética calibrada é global e aditiva, enquanto o erro de produção é numericamente zero. Assim, a robustez altera a garantia reportada, não o ponto ótimo.

3.5 Validação linear

O linprog encontra Flow 694,11; Valve 94,36; Temp 719,43; Pressure 25,35; EI linear 2,765 e Yield linear 72,20. Ele confirma que a vazão domina o surrogate linear. Como a LP simplifica a razão energética e a geometria do histórico, ela é validação de direção, não a recomendação principal.

4. Decisão de manutenção

Os cenários cobrem 30 dias ou 180 intervalos. A manutenção ocupa dois intervalos; a postergada ocorre após 15 dias. Foram assumidos R\$ 130 por unidade de energia, manutenção imediata de R\$ 45 mil, planejada de R\$ 25 mil e falha de R\$ 300 mil.

Cenário	Produção (ton)	Energia (unid.)	Energia (R\$)	Manutenção (R\$)	Exposição a falha (R\$)	Total parcial (R\$)	Parcial/ton (R\$)
Sem manutenção	12.996,56	40.350,05	5.245.506,13	0	190.617,62	5.436.123,76	418,27
Manutenção imediata	21.582,06	39.901,71	5.187.222,73	45.000,00	28.606,89	5.260.829,62	243,76
Manutenção postergada	17.168,06	39.901,71	5.187.222,73	25.000,00	109.294,40	5.321.517,13	309,97

No horizonte fixo, a manutenção imediata reduz o custo parcial em R\$ 175.294,14. Variando isoladamente preço de energia, manutenção e falha em $\pm 30\%$, a economia permanece positiva entre aproximadamente R\$ 127 mil e R\$ 224 mil. A produção, entretanto, é muito diferente entre os cenários.

4.1 Mesma produção e sensibilidade causal

Para entregar as mesmas 10 mil toneladas, o cenário sem manutenção leva 23,08 dias e custa parcialmente R\$ 4.182.742,08; o cenário imediato leva 14,08 dias, incluindo a parada, e custa R\$ 2.461.596,30. Essa diferença depende diretamente da recuperação de saúde assumida.

A recuperação foi calculada linearmente entre dois estados que existem no dataset. O início, 0,578, é o registro real com maior escore de degradação no teste. O destino, 0,970, é uma linha real do treino, da mesma unidade e do mesmo catalisador, escolhida próxima ao centro do grupo com saúde no quartil superior, vibração no quartil inferior e idade do catalisador no quartil inferior. Os pontos de 25%, 50% e 75% são interpolações entre esses registros, não medições realizadas depois de uma manutenção.

Usamos essa interpolação porque $\text{Yield} = 0,18 \times \text{Flow} \times \text{Health}$ é exata nos 10.000 registros. Mantendo a vazão, saúde e produção variam proporcionalmente. Uma recuperação de 50% significa percorrer metade da distância entre 0,578 e 0,970, chegando a 0,774; não significa definir a saúde como 0,50. O ganho econômico não foi presumido como proporcional: ele foi recalculado em cada cenário, incluindo intensidade energética, parada, manutenção e exposição assumida à falha.

Recuperação assumida	Saúde	Yield (ton/4h)	EI	Economia vs. não manter (R\$)
25%	0,68	84,46	2,65	588.821
50%	0,77	96,73	2,32	1.061.953
75%	0,87	108,99	2,06	1.428.630
100%	0,97	121,25	1,85	1.721.146

Interpolando os cenários, a recuperação mínima para empatar fica em aproximadamente 1,8%. Sem recuperação, a intervenção perde exatamente seu custo de R\$ 45 mil. Portanto, o resultado deve ser apresentado como limiar condicionado ao efeito da manutenção, não como ganho causal demonstrado.

Esse resultado é condicional, não um business case real. O dataset não contém preço do produto, margem, custo completo de parada, estoque, demanda ou penalidades. Além disso, o índice de risco foi convertido em probabilidade por premissa; ele não foi calibrado com falhas. No horizonte fixo, o consumo absoluto previsto por intervalo é praticamente constante: a melhora da intensidade vem principalmente do aumento de produção.

O Isolation Forest coloca o estado degradado no percentil 0,44 de normalidade do treino e a referência saudável no percentil 20,11. Isso mostra que o primeiro estado é raro; não estima risco de falha nem prova causalidade.

5. Automação

Decisão	Automação recomendada	Justificativa
Qualidade de dados, scores e alertas	Automática	Alta frequência e reversibilidade
Sugestão de setpoints	Automática supervisionada	Aplicar com limites oficiais e rollback
Parada para manutenção	Recomendação automática e aprovação humana	Segurança, custo e risco não calibrado

Benefícios: velocidade, escala, consistência, monitoramento contínuo e menor tempo até detectar degradação. Riscos: falsos positivos/negativos, sensores incorretos, erro de modelo, drift, extrapolação e impacto de uma parada indevida.

6. Pipeline final

Dados → qualidade e EDA → features sem leakage → walk-forward
 → calibração conformal → teste final → diagnóstico de suporte
 → otimização nominal/robusta → cenários → custo/risco
 → recomendação → aprovação humana de manutenção

7. Tabela final de decisão

Campo	Recomendação
Feedstock Flow	694,11 m³/h
Reactor Temperature	795,14 °C
Reactor Pressure	33,32 bar
Valve Opening	79,53%
Expected Yield	121,25 ton/4h
Energy Intensity	1,849; limite superior conformal de 90% = 2,401
Energy Cost	R\$ 5.187.222,73 em 30 dias
Maintenance	Sim, condicionada à inspeção humana
Maintenance Cost	R\$ 45.000,00 — premissa
Total Cost	R\$ 5.260.829,62 — parcial e ilustrativo
Automação	Setpoints supervisionados; manutenção com aprovação humana

8. Conclusão

Qual configuração foi recomendada? A tabela acima, depois de conferida contra os limites oficiais de engenharia. Ela mantém a produção mínima e permanece próxima de configurações históricas.

A manutenção deve ser realizada? O sistema deve recomendar inspeção imediata. Se os sensores e a degradação forem confirmados, realizar a manutenção. O dataset não justifica parada totalmente automática.

Qual o impacto econômico? No cenário didático, economia parcial de aproximadamente R\$ 175 mil em 30 dias. Em uma meta comum de 10 mil toneladas, a diferença pode chegar a R\$ 1,72 milhão, mas somente sob recuperação integral do estado. Com efeito nulo, a manutenção perde R\$ 45 mil. O valor exclui receitas e custos empresariais relevantes.

Quais os riscos? Erro do modelo de energia, qualidade dos sensores, mudança de processo, extrapolação, premissas financeiras e ausência de dados reais de falha/manutenção.

Automática ou humana? Monitoramento e setpoints com automação supervisionada; manutenção com aprovação humana.

Quais dados faltam para produção? Falhas e ordens de manutenção; condição antes/depois das intervenções; limites de engenharia; preços por fonte de energia; duração e custo das paradas; valor e margem do produto; demanda, estoque e penalidades contratuais.