

Pipeline de ML, Otimização e Decisão de Manutenção — Complexo Petroquímico

Dataset: petrochemical_advanced_data.csv — 10.000 registros, 16 colunas, janeiro de 2020 a julho de 2024 Integrantes:

- Elton Vinícios Almeida de Oliveira — RM 562187
- Emerson dos Santos Silva — RM 562033
- Kelvin Douglas Ribeiro Rabelo — RM 561538
- Pedro Henrique Simão Soares — RM 562283
- Vitor Lucas Mattos de Brito Mariano — RM 562116

1. Entendimento do negócio

O trabalho busca uma configuração operacional que reduza a intensidade energética sem produzir menos que o nível de referência e, em seguida, compara alternativas de manutenção. Há quatro decisões operacionais: vazão, temperatura, pressão e abertura de válvula. A condição do equipamento é representada por saúde do sensor, vibração e idade/tipo do catalisador.

Variável	Classe	Uso
Feedstock_Flow_m3h	Controlável	Variável de decisão
Reactor_Temp_C	Controlável	Variável de decisão
Reactor_Pressure_Bar	Controlável	Variável de decisão
Valve_Opening_Percent	Controlável	Variável de decisão
Sensor_Health_Index	Estado	Indicador de condição; não prova falha
Vibration_Level_mm_s	Estado	Indicador de condição mecânica
Catalyst_Age_Days / Catalyst_Type	Estado	Condição do catalisador
Unit_Name	Estado categórico	Unidade produtiva
Ambient_Temp_C / Timestamp	Externa	Ambiente e sazonalidade
Electricity_MWh / Natural_Gas_m3h / Steam_Tons_h	Resultado pós-operação	Excluídas dos modelos operacionais
Product_Yield_Tons	Target	Produção por intervalo de quatro horas
Energy_Intensity	Target	Intensidade energética por tonelada

Regras adotadas: validação temporal; targets e medições pós-operação fora das features; limites calculados na própria unidade; restrição de produção; restrição de proximidade a configurações observadas; custos e risco tratados como premissas didáticas.

2. Dados e Machine Learning

2.1 Qualidade e exploração

A base não possui nulos, duplicatas completas nem timestamps duplicados. As leituras estão espaçadas em quatro horas e distribuídas de forma equilibrada entre três unidades. As médias dos targets também são semelhantes entre unidades. Vazão e saúde apresentam as associações mais fortes com produção e energia. Temperatura, pressão e válvula têm importância preditiva pequena dentro do domínio observado.

Foram criadas features cíclicas de hora e mês. Unit_Name e Catalyst_Type receberam one-hot encoding. A auditoria também identificou a interação pré-operacional Feedstock_Flow_m3h $\times$ Sensor_Health_Index.

2.2 Target leakage

A auditoria encontrou a identidade exata, com erro numérico máximo de $1,78 \times 10^{-15}$:

$$\text{Energy_Intensity} = (3,6 \times \text{Electricity_MWh} + 0,035 \times \text{Natural_Gas_m3h}) / \text{Product_Yield_Tons}$$

Portanto, eletricidade, gás e produção não podem prever intensidade energética numa decisão anterior à operação. Steam_Tons_h não participa dessa fórmula, corrigindo a interpretação da versão anterior, mas também é uma medição pós-operação e foi excluída.

Foi encontrada ainda a identidade exata, com erro máximo de $2,84 \times 10^{-14}$:

$$\text{Product_Yield_Tons} = 0,18 \times \text{Feedstock_Flow_m3h} \times \text{Sensor_Health_Index}$$

Como vazão e saúde estão disponíveis antes da operação, a interação não é leakage. Ela revela, porém, que a produção da base é sintética e determinística.

2.3 Validação e resultados

Os primeiros 80% formam a janela de desenvolvimento e os 20% finais permanecem intocados até a avaliação final. Dentro do desenvolvimento, 70% ajustam o modelo operacional e 10% calibram a incerteza. Três folds walk-forward expansivos (5.000→1.000, 6.000→1.000 e 7.000→1.000) verificam estabilidade sem usar o teste final.

Target	Modelo	R ²	MAE	RMSE
Energy_Intensity	Linear Regression	0,6801	0,2810	0,3472
Energy_Intensity	Random Forest	0,6825	0,2794	0,3459
Energy_Intensity	Gradient Boosting	0,6888	0,2766	0,3424
Energy_Intensity	Híbrido físico	0,6930	0,2761	0,3401
Product_Yield_Tons	Linear + interação	1,0000	0,0000	0,0000
Product_Yield_Tons	Random Forest	0,9999	0,0126	0,1250
Product_Yield_Tons	Gradient Boosting	0,9999	0,1092	0,1678
Product_Yield_Tons	Híbrido físico	1,0000	0,0000	0,0000

No walk-forward de energia, Gradient Boosting e híbrido ficam tecnicamente empatados: RMSE médio $0,3311 \pm 0,0050$ e $0,3312 \pm 0,0049$, respectivamente. No teste final, o híbrido alcança RMSE 0,3401, contra 0,3424 do Gradient Boosting. Ele foi escolhido pela coerência algébrica e interpretabilidade, não por ajuste ao teste.

A janela separada de 1.000 registros calibrou uma margem conformal absoluta de 90% igual a 0,552. No teste final, o intervalo cobriu 89,4% das observações, valor próximo dos 90% nominais. Para produção, a margem é apenas erro numérico ($1,42 \times 10^{-14}$).

A interação de vazão e saúde domina a previsão de produção. Essa relação determinística descreve como a base foi construída, mas não demonstra que uma manutenção real causará toda a recuperação simulada.

3. Otimização

3.1 Formulação

Seja $x = (\text{Valve_Opening}, \text{Feedstock_Flow}, \text{Reactor_Temp}, \text{Reactor_Pressure})$. Para cada estado do equipamento:

$$\min \text{EI}_{\text{hat}}(x \mid \text{estado}) + 10^{-4} D(x, x_{\text{atual}})$$

sujeito a:

$$\text{Yield}_{\text{hat}}(x \mid \text{estado}) \geq 64,37 \text{ ton/4h}$$

x entre p1 e p99 do histórico da unidade

distância conjunta até uma configuração observada $\leq$ p99 histórico

O termo de movimento apenas desempata soluções em favor de ajustes menores. Usamos `scipy.optimize.differential_evolution` porque a razão de energia e a restrição de vizinhança tornam o problema não linear. Uma busca aleatória com 10.000 candidatos e uma LP com surrogates lineares funcionam como verificações independentes. A distância de suporte combina setpoints, saúde, vibração e idade do catalisador dentro do mesmo ativo/unidade.

3.2 Caso de estudo e estado pós-manutenção

O caso não foi escolhido manualmente. Ele é o maior escore de degradação no período de teste, combinando baixa saúde (50%), alta vibração (35%) e idade do catalisador (15%): Ammonia_Unit_02 em 12/05/2024, saúde 0,578, vibração 8,126 mm/s e catalisador com 348 dias.

O estado pós-manutenção também deixou de combinar percentis extremos artificiais. Ele é uma observação real e central de um grupo saudável da mesma unidade e catalisador no treino: saúde 0,970, vibração 1,749 mm/s e 58 dias.

3.3 Solução

Variável	Sem manutenção	Manutenção imediata
Valve Opening (%)	79,91	79,53
Feedstock Flow (m³/h)	694,11	694,11
Reactor Temperature (°C)	789,03	795,14
Reactor Pressure (bar)	33,36	33,32
Energy Intensity prevista	3,106	1,849
Product Yield previsto (ton/4h)	72,20	121,25
Distância de suporte condicionado	2,032	1,035
Limite de suporte	2,032	2,032

As duas soluções satisfazem a produção mínima e permanecem na região conjunta condicionada ao estado. A solução sem manutenção fica próxima do limite de suporte; a solução pós-manutenção permanece mais central. Como o numerador energético não é previsível com as entradas disponíveis, minimizar intensidade equivale principalmente a elevar a produção. Temperatura, pressão e válvula não devem ser interpretadas como alavancas comprovadas de economia.

3.3 Alternativas por faixa de produção

A fronteira estrita energia–produção colapsa em um ponto, pois o numerador energético é aproximadamente constante e a intensidade cai quando a produção aumenta. Para evitar operar sempre no extremo, foram calculadas metas de produção pós-manutenção com faixa de tolerância de 2%:

Meta relativa à produção atual	Flow	Yield	EI	Distância de suporte
140%	526,21	91,92	2,439	0,799

Meta relativa à produção atual	Flow	Yield	EI	Distância de suporte
150%	563,79	98,48	2,276	0,903
160%	601,38	105,05	2,134	0,929
165%	620,17	108,33	2,069	0,968

Essas alternativas permitem escolher capacidade e intensidade conforme a margem operacional, em vez de aceitar automaticamente a configuração de maior produção.

3.4 Otimização robusta

A formulação robusta minimiza o limite superior conformal de intensidade e exige o limite inferior de produção acima da meta. Com manutenção, a intensidade passa de 1,849 nominal para limite superior 2,401; sem manutenção, de 3,105 para 3,657. Os setpoints não mudam porque a margem energética calibrada é global e aditiva, enquanto o erro de produção é numericamente zero. Assim, a robustez altera a garantia reportada, não o ponto ótimo.

3.5 Validação linear

O linprog encontra Flow 694,11; Valve 94,36; Temp 719,43; Pressure 25,35; EI linear 2,765 e Yield linear 72,20. Ele confirma que a vazão domina o surrogate linear. Como a LP simplifica a razão energética e a geometria do histórico, ela é validação de direção, não a recomendação principal.

4. Decisão de manutenção

Os cenários cobrem 30 dias ou 180 intervalos. A manutenção ocupa dois intervalos; a postergada ocorre após 15 dias. Foram assumidos R\$ 130 por unidade de energia, manutenção imediata de R\$ 45 mil, planejada de R\$ 25 mil e falha de R\$ 300 mil.

Cenário	Produção (ton)	Energia (unid.)	Energia (R\$)	Manutenção (R\$)	Exposição a falha (R\$)	Total parcial (R\$)	Parcial/ton (R\$)
Sem manutenção	12.996,56	40.350,05	5.245.506,13	0	190.617,62	5.436.123,76	418,27
Manutenção imediata	21.582,06	39.901,71	5.187.222,73	45.000,00	28.606,89	5.260.829,62	243,76
Manutenção postergada	17.168,06	39.901,71	5.187.222,73	25.000,00	109.294,40	5.321.517,13	309,97

No horizonte fixo, a manutenção imediata reduz o custo parcial em R\$ 175.294,14. Variando isoladamente preço de energia, manutenção e falha em $\pm 30\%$, a economia permanece positiva entre aproximadamente R\$ 127 mil e R\$ 224 mil. A produção, entretanto, é muito diferente entre os cenários.

4.1 Mesma produção e sensibilidade causal

Para entregar as mesmas 10 mil toneladas, o cenário sem manutenção leva 23,08 dias e custa parcialmente R\$ 4.182.742,08; o cenário imediato leva 14,08 dias, incluindo a parada, e custa R\$ 2.461.596,30. Essa diferença depende diretamente da recuperação de saúde assumida.

Recuperação assumida	Saúde	Yield (ton/4h)	EI	Economia vs. não manter (R\$)
25%	0,68	84,46	2,65	588.821

Recuperação assumida	Saúde	Yield (ton/4h)	EI	Economia vs. não manter (R\$)
50%	0,77	96,73	2,32	1.061.953
75%	0,87	108,99	2,06	1.428.630
100%	0,97	121,25	1,85	1.721.146

Interpolando os cenários, a recuperação mínima para empatar fica em aproximadamente 1,8%. Sem recuperação, a intervenção perde exatamente seu custo de R\$ 45 mil. Portanto, o resultado deve ser apresentado como limiar condicionado ao efeito da manutenção, não como ganho causal demonstrado.

Esse resultado é condicional, não um business case real. O dataset não contém preço do produto, margem, custo completo de parada, estoque, demanda ou penalidades. Além disso, o índice de risco foi convertido em probabilidade por premissa; ele não foi calibrado com falhas. No horizonte fixo, o consumo absoluto previsto por intervalo é praticamente constante: a melhora da intensidade vem principalmente do aumento de produção.

O Isolation Forest coloca o estado degradado no percentil 0,44 de normalidade do treino e a referência saudável no percentil 20,11. Isso mostra que o primeiro estado é raro; não estima risco de falha nem prova causalidade.

5. Automação

Decisão	Automação recomendada	Justificativa
Qualidade de dados, scores e alertas	Automática	Alta frequência e reversibilidade
Sugestão de setpoints	Automática supervisionada	Aplicar com limites oficiais e rollback
Parada para manutenção	Recomendação automática e aprovação humana	Segurança, custo e risco não calibrado

Benefícios: velocidade, escala, consistência, monitoramento contínuo e menor tempo até detectar degradação. Riscos: falsos positivos/negativos, sensores incorretos, erro de modelo, drift, extrapolação e impacto de uma parada indevida.

6. Pipeline final

Dados → qualidade e EDA → features sem leakage → walk-forward
 → calibração conformal → teste final → diagnóstico de suporte
 → otimização nominal/robusta → cenários → custo/risco
 → recomendação → aprovação humana de manutenção

7. Tabela final de decisão

Campo	Recomendação
Feedstock Flow	694,11 m³/h
Reactor Temperature	795,14 °C
Reactor Pressure	33,32 bar
Valve Opening	79,53%
Expected Yield	121,25 ton/4h
Energy Intensity	1,849; limite superior conformal de 90% = 2,401
Energy Cost	R\$ 5.187.222,73 em 30 dias

Campo	Recomendação
Maintenance	Sim, condicionada à inspeção humana
Maintenance Cost	R\$ 45.000,00 — premissa
Total Cost	R\$ 5.260.829,62 — parcial e ilustrativo
Automação	Setpoints supervisionados; manutenção com aprovação humana

8. Conclusão

Qual configuração foi recomendada? A tabela acima, depois de conferida contra os limites oficiais de engenharia. Ela mantém a produção mínima e permanece próxima de configurações históricas.

A manutenção deve ser realizada? O sistema deve recomendar inspeção imediata. Se os sensores e a degradação forem confirmados, realizar a manutenção. O dataset não justifica parada totalmente automática.

Qual o impacto econômico? No cenário didático, economia parcial de aproximadamente R\$ 175 mil em 30 dias. Em uma meta comum de 10 mil toneladas, a diferença pode chegar a R\$ 1,72 milhão, mas somente sob recuperação integral do estado. Com efeito nulo, a manutenção perde R\$ 45 mil. O valor exclui receitas e custos empresariais relevantes.

Quais os riscos? Erro do modelo de energia, qualidade dos sensores, mudança de processo, extrapolação, premissas financeiras e ausência de dados reais de falha/manutenção.

Automática ou humana? Monitoramento e setpoints com automação supervisionada; manutenção com aprovação humana.

Quais dados faltam para produção? Falhas e ordens de manutenção; condição antes/depois das intervenções; limites de engenharia; preços por fonte de energia; duração e custo das paradas; valor e margem do produto; demanda, estoque e penalidades contratuais.